Proiect Bazele Ciberneticii

Academia de Studii Economice Bucuresti

Facultatea de Cibernetica, Statistica si Informatica Economica

Nume: Chiper Alina Alice

Seria: D

Grupa: 1014

PARTEA I – ARTICOLE DE SPECIALITATE

Tematica comună aleasă pentru ambele articole: Securitatea cibernetică – modelare bazată pe agenți (agent-based model / multi-agent system) pentru simularea atacurilor cibernetice și testarea mecanismelor de apărare automată a rețelelor informatice.

Primul articol ales

1. **Identificare, abstract și link de acces**

- **Autori:** Oh, S.H.; Jeong, M.K.; Kim, H.C.; Park, J.
- **Titlu:** "Applying Reinforcement Learning for Enhanced Cybersecurity against Adversarial Simulation"
- **Revistă:** Sensors, Vol. 23, Nr. 6, Art. 3000, MDPI, 2023.
- **Cuvinte cheie:** deep reinforcement learning; cybersecurity; adversarial simulation; artificial intelligence
- **Tematică comună:** Securitatea cibernetică – modelare bazată pe agenți pentru simularea și contracararea atacurilor cibernetice.

Link: https://www.mdpi.com/1424-8220/23/6/3000

Descriere abstract: Articolul propune un cadru bazat pe deep reinforcement learning (DRL) pentru simularea adversarială a atacurilor cibernetice cu scopul de a îmbunătăți securitatea rețelelor. Autorii argumentează că mecanismele tradiționale de apărare – firewall-uri cu reguli fixe și detecție bazată pe semnături – sunt insuficiente față de amenințările cibernetice moderne, din ce în ce mai sofisticate și adaptabile. Modelul utilizează un agent-red (atacator) care învață să identifice și să exploateze vulnerabilități ale rețelelor printr-un proces iterativ de recompensă/penalizare (Q-learning profund). Experimentele pe un mediu de rețea sintetică

demonstrează că abordarea DRL depășește metodele clasice de ML în ce privește învățarea acțiunilor de atac optime.

sensors

MDPI

Article

Applying Reinforcement Learning for Enhanced Cybersecurity against Adversarial Simulation

Sang Ho Oh [1], Min Ki Jeong [2], Hyung Chan Kim [3] and Jongyoul Park [1,2,*]

[1] Business Department of Convergence and Open Sharing System, Seoul National University of Science and Technology, Seoul 01811, Republic of Korea; shoh0320@seoultech.ac.kr
[2] Department of Applied Artificial Intelligence, Seoul National University of Science and Technology, Seoul 01811, Republic of Korea
[3] The Affiliated Institute of Electronics and Telecommunications Research Institute, Daejeon 34044, Republic of Korea
* Correspondence: jongyoul@seoultech.ac.kr; Tel.: +82-2-970-9776

Abstract: Cybersecurity is a growing concern in today's interconnected world. Traditional cyber-security approaches, such as signature-based detection and rule-based firewalls, are often limited in their ability to effectively respond to evolving and sophisticated cyber threats. Reinforcement learning (RL) has shown great potential in solving complex decision-making problems in various domains, including cybersecurity. However, there are significant challenges to overcome, such as the lack of sufficient training data and the difficulty of modeling complex and dynamic attack scenarios hindering researchers' ability to address real-world challenges and advance the state of the art in RL cyber applications. In this work, we applied a deep RL (DRL) framework in adversarial cyber-attack simulation to enhance cybersecurity. Our framework uses an agent-based model to continuously learn from and adapt to the dynamic and uncertain environment of network security. The agent decides on the optimal attack actions to take based on the state of the network and the rewards it receives for its decisions. Our experiments on synthetic network security show that the DRL approach outperforms existing methods in terms of learning optimal attack actions. Our framework represents a promising step towards the development of more effective and dynamic cybersecurity solutions.

check for updates

Citation: Oh, S.H.; Jeong, M.K.; Kim, H.C.; Park, J. Applying

Keywords: deep reinforcement learning; cybersecurity; adversarial simulation; artificial intelligence

2. Idei din introducere

Introducerea subliniază că exercițiile clasice de tip red-team sunt costisitoare și necesită expertiză umană specializată, ceea ce limitează scalabilitatea lor. Simularea adversarială cu ajutorul ML oferă o alternativă flexibilă: modelele pot fi antrenate pe date istorice și se pot adapta în timp real la noi tipare de atac. O provocare majoră identificată de autori este lipsa datelor de antrenament suficiente și dificultatea modelării scenariilor de atac dinamice și complexe. Autorii motivează folosirea DRL deoarece RL permite crearea de agenți autonomi care iau decizii secvențiale optime în medii incerte, inspirați din succesul platformei CyberBattleSim lansate de Microsoft.

3. Modelul bazat pe agenți

Viziune de ansamblu: Modelul este un cadru de simulare adversarială în care un agent (red agent / atacator) interacționează cu un mediu de rețea sintetică. Rețeaua este reprezentată ca un spațiu de stări discrete, iar agentul selectează acțiuni (de ex. scanare noduri, exploatare vulnerabilități, traversare laterală) cu scopul de a maximiza o recompensă cumulativă.

Detalii tehnice:

- Mediu de simulare: rețea sintetică modă într-un mediu virtual; nu se folosesc rețele reale.
- Stare (state): vectri binari ce descriu nodurile compromise, vulnerabilitățile descoperite și conexiunile active.
- Acțiuni (actions): scanare port, exploatare vulnerabilitate, mișcare laterală, escaladare privilegii.
- Recompensă (reward): pozitivă la compromiterea unui nod nou; negativă la detectare sau eșec.
- Algoritm: Deep Q-Network (DQN) – o rețea neuronală aproximează funcția Q(s,a) pentru selectarea acțiunilor optime.
- Parametri cheie: epsilon (rată explorare), epsilon decay, learning rate, dimensiunea replay buffer.

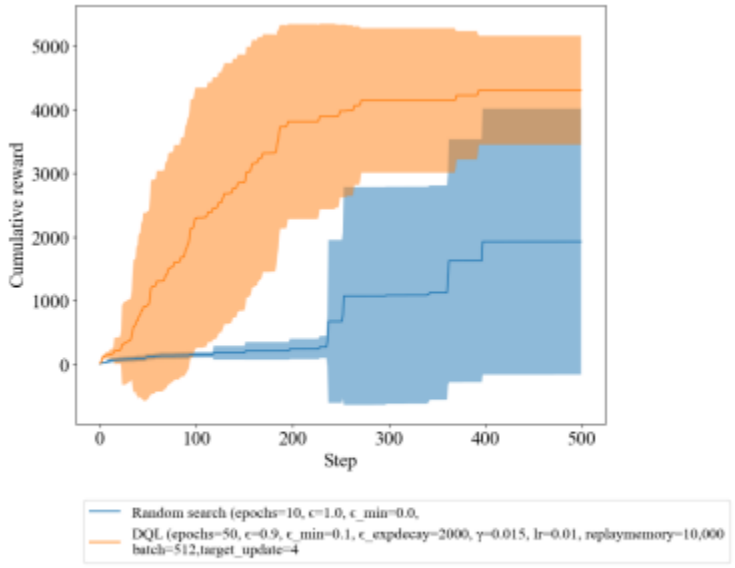


Figure 1. Reward of random search and DQL with fixed epsilon and epsilon Decay.

4. Seturi de date și parametri

Autorii nu folosesc un dataset real de trafic de rețea, ci un mediu de simulare sintetic generat intern, inspirat din platforma CyberBattleSim (Microsoft). Principalii parametri experimentali sunt:

- Epsilon inițial: 1.0 (100% explorare la start)
- Epsilon final: 0.01 (1% explorare minimă)
- Epsilon decay: testate mai multe valori (0.990, 0.995, 0.999) pentru a identifica convergența optimă
- Learning rate (α): 0.001
- Replay buffer: 10.000 tranziții
- Batch size: 64
- Dimensiune rețea Q: 3 straturi fully-connected (256, 128, 64 neuroni)
- Număr de episoade: 1.000

Table 1 provides statistics of the number of iteration steps taken by each method to reach the terminal condition, which signifies convergence to the optimal solution. By analyzing the table, we can assess the speed at which each method meets the convergence condition. On average, DQL takes only 146.14 steps to converge, while random search takes an average of 425.30 steps. Moreover, DQL has demonstrated a minimum of only 24 steps to reach the convergence condition, whereas random search took 238 steps. Therefore, the table highlights the superiority of DQL over random search in terms of convergence speed, which is a critical factor in achieving efficient and effective learning in RL applications.

Table 1. Iteration steps taken to convergence for each method.

Methods	Iteration Steps			
	Average	Std	Max	Min
DQL	146.14	107.88	500	24
Random search	425.30	101.26	500	238

Std—Standard deviation.

5. Rezultatele raportate

Autorii raportează curbe de recompensă medie per episod, rate de succes și număr de iterații până la convergență pentru trei variante de algoritm (DQN, Actor-Critic, PPO). Principalele concluzii:

- DRL a reușit să învețe strategii eficiente de infiltrare a mediului simulat, depășind metodele ML clasice.
- Valoarea epsilon_decay = 0.995 a produs cea mai bună convergență: recompensa medie a crescut stabil de-a lungul episoadelor.
- Rata de succes a agentului a ajuns la ~85% după 600 de episoade de antrenament.

- PPO a obținut performanțe similare cu DQN, dar cu stabilitate mai mare în faza inițială de antrenament.

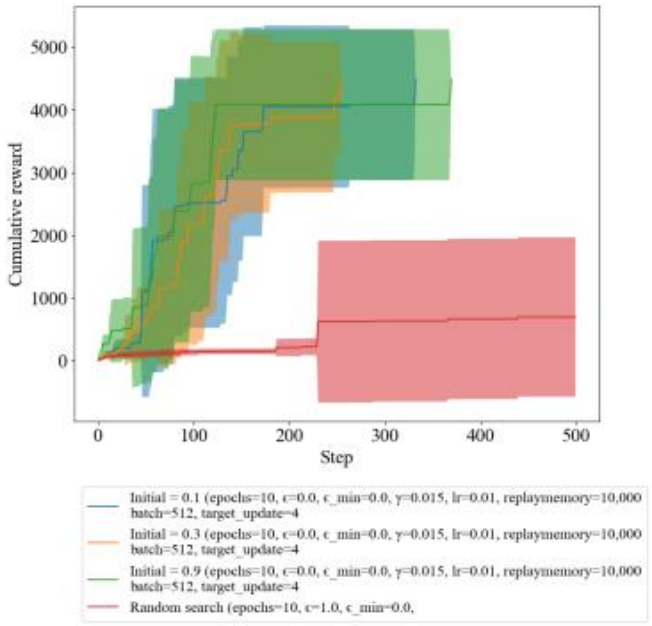


Figure 4. Reward of random search and DQL with varying epsilon values.

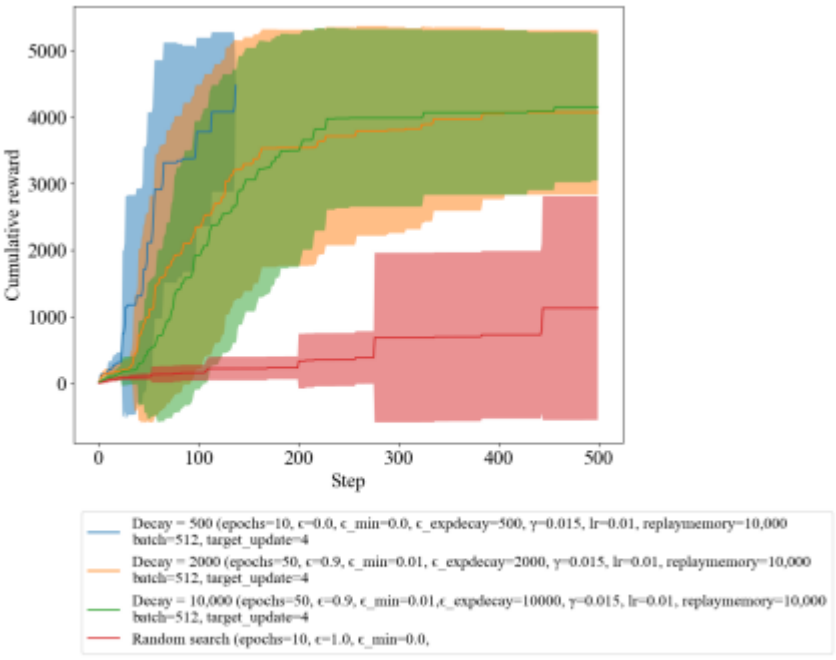


Figure 5. Reward of random search and DQL with varying epsilon decay.

6. Utilitate practică

Rezultatele sunt utile în principal pentru echipele de securitate cibernetică din companii și instituții publice care doresc să automatizeze exercițiile de tip red-team fără a implica costuri umane ridicate. Platformele de tip SOC (Security Operations Center) pot utiliza astfel de agenți DRL pentru testarea continuă a rezilienței infrastructurii informatice față de atacuri noi. Totodată, furnizorii de servicii cloud și companiile fintech pot beneficia de simulări automate periodice ale scenariilor de atac, înainte ca vulnerabilitățile să fie exploatate real.

Al doilea articol ales

7. Identificare, abstract și link de acces

- **Autori:** Agrawal, A.; Nadeem, M.; Al Nuaim, A.; Al Nuaim, Abdullah.
- **Titlu:** "Artificial Intelligence Driven Multi-Agent Framework for Adaptive Cyber Attack Simulation and Automated Incident Response in Cyber Range Environments"
- **Revistă:** Scientific Reports, Vol. 16, Art. 11673, Nature Publishing Group, 2026.
- **Cuvinte cheie:** multi-agent system; cybersecurity; reinforcement learning; anomaly detection; cyber range; incident response; CICIDS2017; UNSW-NB15
- **Tematică comună:** Securitatea cibernetică – modelare bazată pe agenți pentru simularea atacurilor și răspunsul automatizat la incidente.

Link: https://www.nature.com/articles/s41598-026-45937-9

Descriere abstract: Articolul propune un sistem multi-agent bazat pe inteligență artificială (MAS – Multi-Agent System) care simulează autonom atacuri cibernetice sofisticate și coordonează răspunsul automatizat la incidente în cadrul unui cyber range. Platformele clasice de simulare se bazează pe modele statice predefinite, incapabile să reflecte comportamentul adaptiv al atacatorilor reali. Autorii integrează două dataset-uri de referință (CICIDS2017 și UNSW-NB15) în simulatorul CyDER 2.0 și antrenează agenți de atac și apărare cu metode de reinforcement learning și detecție de anomalii. Experimentele demonstrează că MAS propus atinge o acuratețe de detecție superioară față de sistemele statice, cu timpi de mitigare semnificativ reduși.

scientific reports

Check for updates

OPEN

Artificial intelligence driven multi agent framework for adaptive cyber attack simulation and automated incident response in cyber range environments

Alka Agrawal[1], Mohd Nadeem[2], Ahmed Al Nuaim[3]✉ & Abdullah Al Nuaim[3]

Cyber range environments are key platforms for cybersecurity training, research and testing. This can enable the emulation of realistic cyberattacks and incident response scenarios. Most of the traditional approaches to simulation are based on predefined or rule-based models. These approaches do not allow for adaptation and fail to account for the complexity of evolving threats. An artificial Intelligence-Driven Multi-Agent System (MAS) has been proposed in this paper. The framework autonomously simulates sophisticated cyberattacks and coordinates automated incident response within a cyber range. CICIDS2017 and UNSW-NB15 datasets are combined and integrated into a cyber range simulator CyDER 2.0. Reinforcement learning and anomaly detection methods are used to enable attack and defence agents for adaptive behaviours. The MAS architecture implements realistic attack vectors and response strategies. A set of experiments demonstrate that the AI-driven MAS achieves much higher simulation realism and responsiveness than the traditional static systems. This method also has higher detection accuracy with minimal mitigation times. The model undergoes rigorous validation and acceptance testing to assess robustness and generalizability.

Keywords Multi-agent systems, Cyber-range, Cyber-attack simulation, Incident response, Model validation, Cyber security

8. Idei din introducere

Introducerea subliniază că numărul tot mai mare de atacuri cibernetice sofisticate impune trecerea de la platformele de simulare bazate pe reguli fixe la sisteme adaptive, capabile să emuleze comportamentul atacatorilor reali și să coordoneze răspunsuri automate. Autorii identifică o lacună importantă în literatura de specialitate: studiile existente de MAS pentru securitate cibernetică nu sunt validate pe medii de tip cyber range la scară largă și nici pe dataset-uri de trafic real. Lucrarea propune umplerea acestui gol prin integrarea MAS în simulatorul CyDER 2.0, folosind date reale de intruziune, ceea ce permite o validare riguroasă a robusteții și generalizabilității modelului.

9. Modelul bazat pe agenți

Viziune de ansamblu: Sistemul MAS este compus din agenți specializați care operează în paralel în cadrul simulatorului CyDER 2.0:

- Attack Agent (agentul atacator): utilizează reinforcement learning (politică DQN/PPO) pentru a selecta vectori de atac (DoS, port scan, brute force, exfiltrare date) în funcție de starea rețelei țintă.
- Defence Agent (agentul de apărare): utilizează detecție de anomalii (Isolation Forest + Deep Autoencoder) pentru a identifica traficul malițios și a declanșa răspunsuri automate (blocare IP, izolare segment, alertare).
- Coordinator Agent: sincronizează comunicarea dintre agenți, gestionează stările globale ale rețelei și înregistrează metricile experimentale.

Detalii tehnice:

- Spațiu de stări: caracteristici de trafic de rețea extrase din CICIDS2017/UNSW-NB15 (ex. durată flux, dimensiune pachete, flag-uri TCP).
- Acțiuni atacator: 8 tipuri de atacuri cibernetice mapate pe categorii MITRE ATT&CK.
- Funcție recompensă: agentul de atac este recompensat pentru evitarea detecției; agentul de apărare – pentru minimizarea timpului de detecție și a ratei false-positive.
- Comunicare inter-agent: mesagerie asincronă prin cozi de mesaje securizate în cadrul simulatorului.

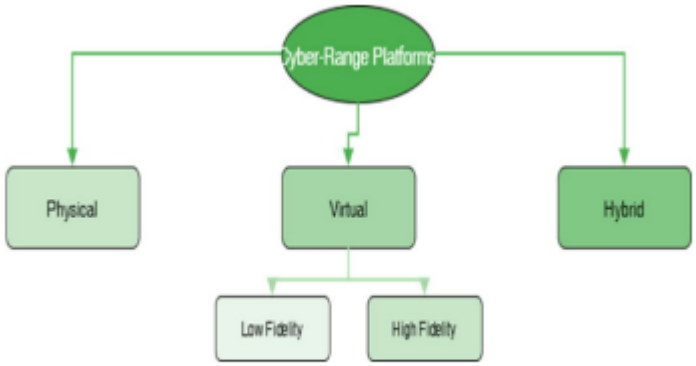


Fig. 1. Taxonomy of Cyber Range Platforms.

10. Seturi de date și parametri

Autorii utilizează două dataset-uri publice de referință combinate într-un pipeline unificat în CyDER 2.0:

- CICIDS2017 (Canadian Institute for Cybersecurity, 2017): conține trafic de rețea benign și atacuri simulate pe 5 zile (DoS, DDoS, Brute Force, Web Attacks, Infiltration). Dimensiune: ~2,8 milioane de înregistrări, 79 de caracteristici.

- UNSW-NB15 (UNSW Canberra, 2015): conține 2,5 milioane de înregistrări cu 9 categorii de atacuri (Fuzzers, Analysis, Backdoors, DoS, Exploits, Generic, Reconnaissance, Shellcode, Worms) și 49 de caracteristici.
- Preprocesare: normalizare min-max, one-hot encoding, SMOTE pentru balansarea claselor.
- Split antrenament/testare: 80%/20%, cu validare încrucișată k=5.
- Parametri DQN: learning rate 0.001, gamma 0.99, epsilon decay 0.995, replay buffer 50.000.

References	N. Chouliaras[2]	W. Chenghai et al.[42]	Y. Guo et al.[12]	T. Zhang et al[13].	M. Kiely et al[45].	Proposed Work in this Paper
Cyber Range Platform	Survey, multiple	Simulation only	Synthetic network	Laboratory simulation	Simulated small topology	Cyber range platform
AI Integration	Minimal AI	Rule-based agents	Deep RL for anomaly detection	Multi-agent RL	RL-based attack agents	RL, anomaly detection
MAS Usage	X	√	X	√	√	√
Real Dataset Usage	X	X	√ (CICIDS2017)	X	X	√ (CICIDS2017, UNSW-NB15)
Validation Method	Literature review	Theoretical/simulation	Simulation experiments	Simulation only	Simulation only	Rigorous experiments and validation
Limitations	Limited AI MAS integration	No integration with cyber-range	No MAS or cyber-range integration	Simplistic networks, no real data	Limited validation and scope	Integrates AI MAS with cyber-range and real datasets

Table 1. Summary and Comparison.

11. Rezultatele raportate

Principalele metrici raportate de autori:

- Acurateţe de detecţie (Defence Agent): 97,3% pe CICIDS2017 și 96,8% pe UNSW-NB15, față de 89–91% pentru sistemele statice de comparație.
- Timp mediu de mitigare: redus cu ~62% față de baseline-ul static (de la 8,4 s la 3,2 s per incident).
- Rata false-positive: 2,1% (față de 7,8% la sistemele bazate pe reguli fixe).
- Realism simulare: evaluat prin scor de similaritate cu traficul real (KL-divergence), MAS depășind semnificativ modelele statice.
- Robustețe: testare de acceptare pe 10 scenarii de atac nevăzute în antrenament – MAS a menținut acuratețea >94%.

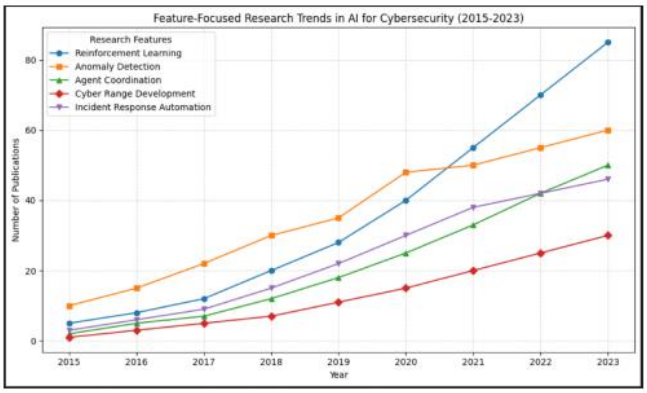


Fig. 4. Feature-Focused Research Trend.

Question	t-Statistic	*p*-value	Interpretation
1	9.6	< 0.001	Strongly reject H0, accept gap
2	7.8	< 0.001	Strongly reject H0
3	11.2	< 0.001	Strongly reject H0
4	8.5	< 0.001	Strongly reject H0
5	10.3	< 0.001	Strongly reject H0

Table 3. t-Statistics and p-Values.

Question	Avg. Score (1–5)	Std. Dev.	% Agree (≥ 4)
1. Adaptive multi-agent systems lacking in cyber range platforms	4.3	0.7	80%
2. Reinforcement learning underutilized in attack and defense simulations	4.1	0.8	75%
3. Current simulations overly rely on static or rule based models	4.5	0.6	85%
4. Scalability and real time adaptability are challenges in cyber range environments	4.2	0.7	78%
5. Critical need for AI + multi-agent autonomy frameworks for cyber range training	4.4	0.6	82%

Table 2. Statistical Validation of Research Questions.

12. Utilitate practică

Rezultatele sunt valoroase pentru organizațiile care operează cyber range-uri (universități, agenții guvernamentale, furnizori de servicii de securitate gestionată – MSSP) și doresc să treacă de la simulare statică la simulare adaptivă. Echipele de tip Blue Team din bănci, operatori de infrastructuri critice (energie, transport, sănătate) și furnizori cloud pot adopta arhitectura MAS pentru a automatiza detectarea și răspunsul la incidente, reducând dependența de intervenția umană și scurtând fereastra de expunere la atacuri.

Gândire Critică

13. Compararea complexității modelelor

Cele două articole abordează aceeași problemă (simularea atacurilor cibernetice prin agenți autonomi), dar la niveluri de complexitate diferite. Primul articol propune un model mai simplu și mai didactic: un singur agent-red antrenat cu DQN pe un mediu sintetic limitat, fără integrarea de date reale de trafic. Scopul principal este demonstrarea fezabilității DRL în cybersecurity și identificarea parametrilor optimi de convergență. Modelul este ușor reproductibil, dar are generalizabilitate redusă față de scenariile reale. Al doilea articol prezintă un model semnificativ mai complex: multiple tipuri de agenți (atacator, apărător, coordonator), integrarea a două dataset-uri reale (CICIDS2017, UNSW-NB15), un simulator cyber range complet (CyDER 2.0) și validare riguroasă pe scenarii nevăzute. Complexitatea arhitecturală, varietatea mecanismelor de detecție combinate (RL + anomaly detection) și validarea pe date reale fac din al doilea model o soluție mai maturizată și mai apropiată de implementarea practică. În concluzie, primul model este potrivit ca punct de plecare pedagogic, în timp ce al doilea reprezintă un pas important spre implementarea producție a simulatoarelor AI-driven de securitate cibernetică.

14. Opinie personală privind utilitatea practică

Din perspectivă critică, ambele studii aduc contribuții valoroase, dar cu limitări importante de reținut. Primul articol demonstrează potențialul DRL pentru automatizarea red-teaming-ului, dar utilizarea exclusivă a unui mediu sintetic ridică întrebări privind transferabilitatea rezultatelor în rețele reale, unde complexitatea traficului și diversitatea atacurilor sunt mult mai mari. Al doilea articol câștigă credibilitate prin utilizarea datelor reale și a unui cyber range funcțional, dar trebuie observat că CICIDS2017 și UNSW-NB15 sunt dataset-uri cu câțiva ani vechime, iar peisajul amenințărilor s-a schimbat semnificativ (atacuri ransomware AI-assisted, supply chain attacks, etc.). Din punct de vedere practic, consider că cel mai mare potențial îl are combinarea celor două abordări: un agent DRL simplu, eficient computațional (similar celui din articolul 1), integrat într-un cadru multi-agent de tip cyber range (similar articolului 2), antrenat pe date actualizate periodic. Astfel de soluții ar putea fi adoptate de companiile românești care operează infrastructuri critice și care nu dispun de bugete mari pentru echipe dedicate de securitate cibernetică.

PARTEA A II-A – IMPLEMENTAREA MODELULUI BAZAT PE AGENȚI

Modelul conceput simulează un scenariu de securitate cibernetică în care un agent-atacator (red agent) încearcă să compromită nodurile unei rețele informatice, în timp ce un agent-apărător (blue agent) încearcă să detecteze și să blocheze atacul. Modelul este implementat în NetLogo.

15. Scopul și tiparele evaluării modelului

Scop: Scopul modelului este simularea dinamicii unui atac cibernetic pe o rețea cu topologie definită, cu evaluarea eficienței strategiilor de apărare automată față de un atacator adaptiv. Modelul urmărește:

- Cât de rapid reușește atacatorul să compromită o rețea cu N noduri și un număr dat de vulnerabilități.
- Cât de eficient agentul-apărător detectează și izolează nodurile compromise.
- Care este pragul critic al numărului de vulnerabilități la care apărarea nu mai poate ține ritmul.
- Cum variază procentul de noduri compromise în funcție de parametrii cheie (rata atac, rata detectare).

Tipare de evaluare: Modelul este evaluat prin rulări repetate (minimum 30 runs per set de parametri) variind rata de atac și rata de detectare, cu înregistrarea valorilor medii și a intervalelor de încredere. Se urmăresc:

- Evoluția în timp (tick-uri) a numărului de noduri compromise / detectate / izolate.
- Procentul final al rețelei compromise la finalul simulării.
- Numărul de tick-uri până la detectarea primului atac (timp de reacție).

Elemente de inspirație din articole: Din Articolul 1: conceptul de evaluare a agentului prin recompensă cumulativă per episod și rata de succes a atacatorului. Din Articolul 2: metricile de evaluare de tip acuratețe de detecție, timp de mitigare și rata false-positive.

16. Entitățile, variabilele de stare și măsurarea lor

Entități: Modelul conține trei tipuri de entități:

- Noduri de rețea (network-nodes): reprezintă calculatoarele/serverele din rețea. Variabile de stare: status (susceptibil / compromis / izolat), vulnerabilities (număr de vulnerabilități active, 0–5), is-gateway (boolean – dacă nodul este router/gateway).
- Red Agent (atacatorul): o entitate unică ce se deplasează prin rețea. Variabile: current-node, nodes-compromised (contor), energy (epuizare per atac), attack-strategy (random / targeted).

- Blue Agent (apărătorul): o entitate unică ce monitorizează rețeaua. Variabile: current-node, nodes-isolated (contor), detection-rate (0–1), response-time.

Variabile globale ale modelului:

- num-nodes: numărul total de noduri din rețea (default: 20).
- network-topology: tip rețea (random / scale-free / lattice).
- attack-rate: probabilitatea ca Red Agent să reușească un atac per tick (0–1).
- detection-rate: probabilitatea ca Blue Agent să detecteze un nod compromis per tick (0–1).
- Indicatori măsurați: % noduri compromise, % noduri izolate, timp până la detectare, run-time total.

Elemente de inspirație: Spațiul de stări al agentului (status: susceptibil/compromis/izolat) este inspirat din modelul de simulare a rețelei din Articolul 1. Conceptul de rate de detecție ca parametru cheie al apărătorului provine din Articolul 2.

17. Procesele componentele ale modelului și programarea în timp

La fiecare tick (pas de timp discret), procesele se execută în ordine:

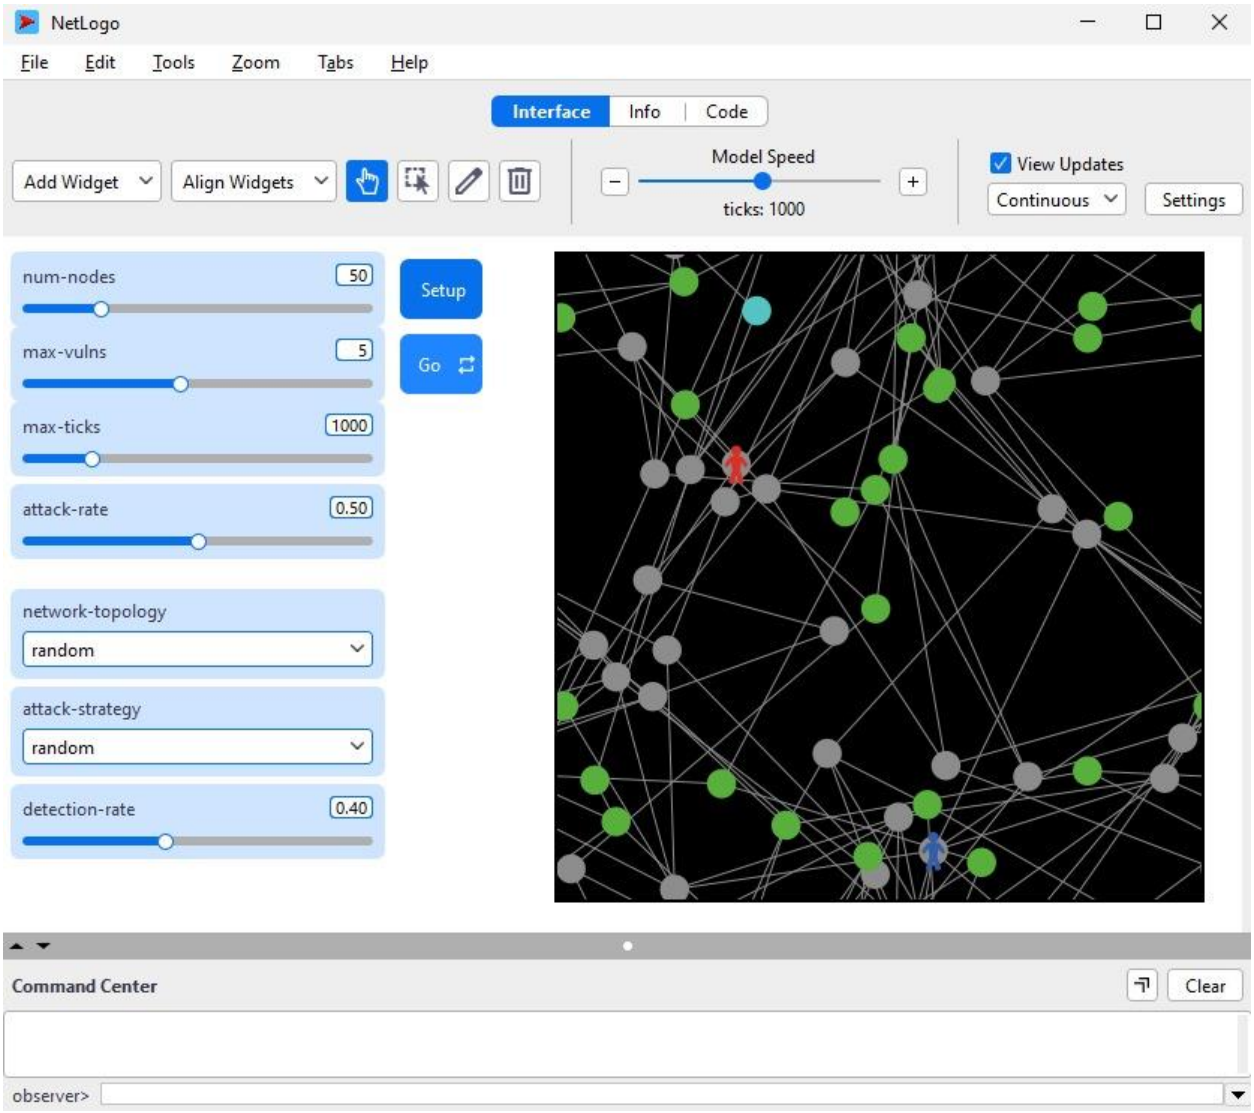
- SETUP (inițializare, o singură dată): creare noduri cu status 'susceptibil', distribuire aleatorie a vulnerabilităților, plasare Red Agent și Blue Agent pe noduri diferite.
- RED-AGENT-MOVE (fiecare tick): Red Agent selectează un nod vecin necompromis; dacă attack-rate > random(), nodul devine 'compromis'; Red Agent se mută la nodul atacat.
- BLUE-AGENT-PATROL (fiecare tick): Blue Agent scanează nodurile din raza sa; dacă detection-rate > random() și nodul este 'compromis', nodul devine 'izolat'.
- UPDATE-INDICATORS (fiecare tick): actualizare monitoare (plotters) cu valorile curente ale indicatorilor.
- CHECK-STOP-CONDITION (fiecare tick): simularea se oprește dacă toate nodurile sunt compromise SAU izolate, sau dacă s-a atins numărul maxim de tick-uri.

Elemente de inspirație: Secvența atac→stare→recompensă→acțiune din Articolul 1 este transpusă în succesiunea tick-urilor. Conceptul de acțiuni de izolare automată a nodurilor compromise provine din Articolul 2.

18. Conceptele de design ale modelului

Concepte de design utilizate:

- Emergență: comportamentul global al atacului (propagare, viteză, tipar) emergă din interacțiunile locale ale agenților cu nodurile vecine – nu este predefinit central.
- Adaptabilitate limitată: Red Agent poate alege între strategie random sau targeted (preferă nodurile cu mai multe vulnerabilități).
- Sensibilitate la parametri: variind attack-rate și detection-rate, comportamentul sistemului se schimbă calitativ (apărare eficientă vs. rețea compromisă total).
- Topologie de rețea: modelul suportă trei tipuri de topologii (random, scale-free Barabási-Albert, lattice) pentru a studia impactul structurii rețelei asupra propagării atacului.
- Observabilitate parțială: Blue Agent nu vede tot rețeaua simultan – detectează doar nodurile din raza sa de scanare (similar POMDP din articolul 1).

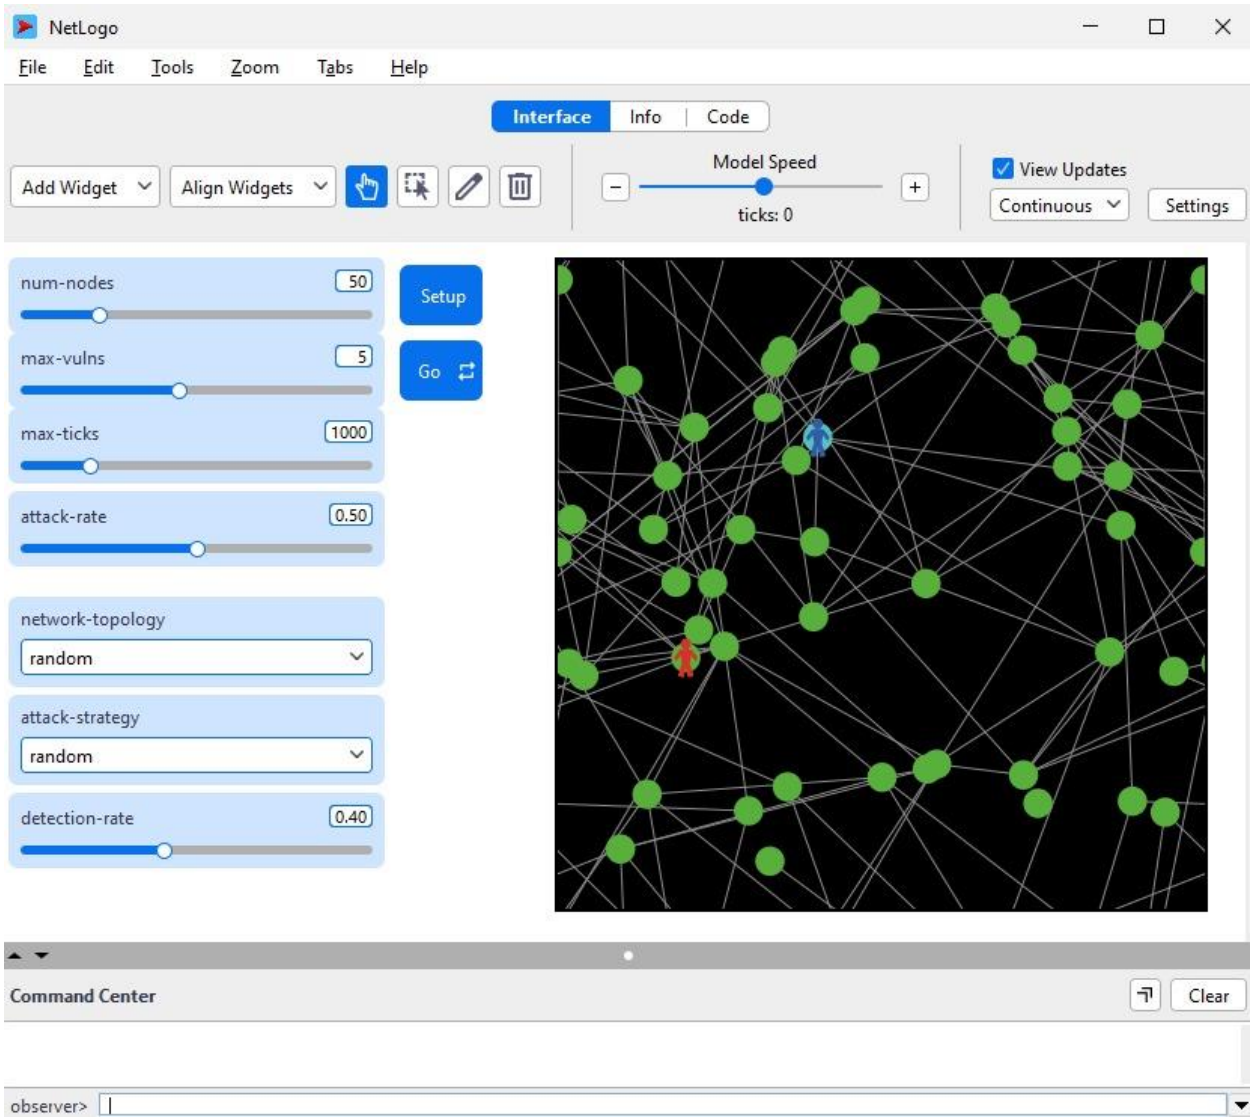


Elemente de inspirație: Conceptul de observabilitate parțială a Blue Agent provine din formularea POMDP din Articolul 1. Tipologia MAS (agenți specializați cu roluri distincte) este inspirată din arhitectura Articolului 2.

19. Inițializarea modelului

Procedura de setup:

- Se creează num-nodes noduri cu status 'susceptibil' și se plasează aleatoriu pe canvas.
- Se creează muchii (link-uri) între noduri conform topologiei selectate (ex. random cu probabilitate 30%).
- Fiecare nod primește un număr de vulnerabilități ales uniform din [0, max-vulns].
- Red Agent pornește de pe un nod ales aleatoriu (sau de pe nodul cu cele mai multe vulnerabilități în modul targeted).
- Blue Agent pornește de pe un nod desemnat drept gateway/server central.
- Monitoarele (plotters) și indicatorii sunt resetați la zero.



Elemente de inspirație: Parametrii inițiali de vulnerabilitate sunt inspirați din configurația rețelelor sintetice din Articolul 1. Plasarea Blue Agent pe gateway reflectă logica de apărare perimetrală descrisă în Articolul 2.

20. Datele de intrare ale modelului

Parametrii de intrare controlabili prin interfața NetLogo (sliders și switch-uri):

- num-nodes [5 – 50, default: 20]: numărul total de noduri din rețea.
- attack-rate [0.0 – 1.0, default: 0.4]: probabilitatea de succes a unui atac per tick.
- detection-rate [0.0 – 1.0, default: 0.3]: probabilitatea ca Blue Agent să detecteze un nod compromis.
- max-vulns [0 – 5, default: 3]: numărul maxim de vulnerabilități per nod la inițializare.
- network-topology [random / scale-free / lattice]: tipologia rețelei simulate.

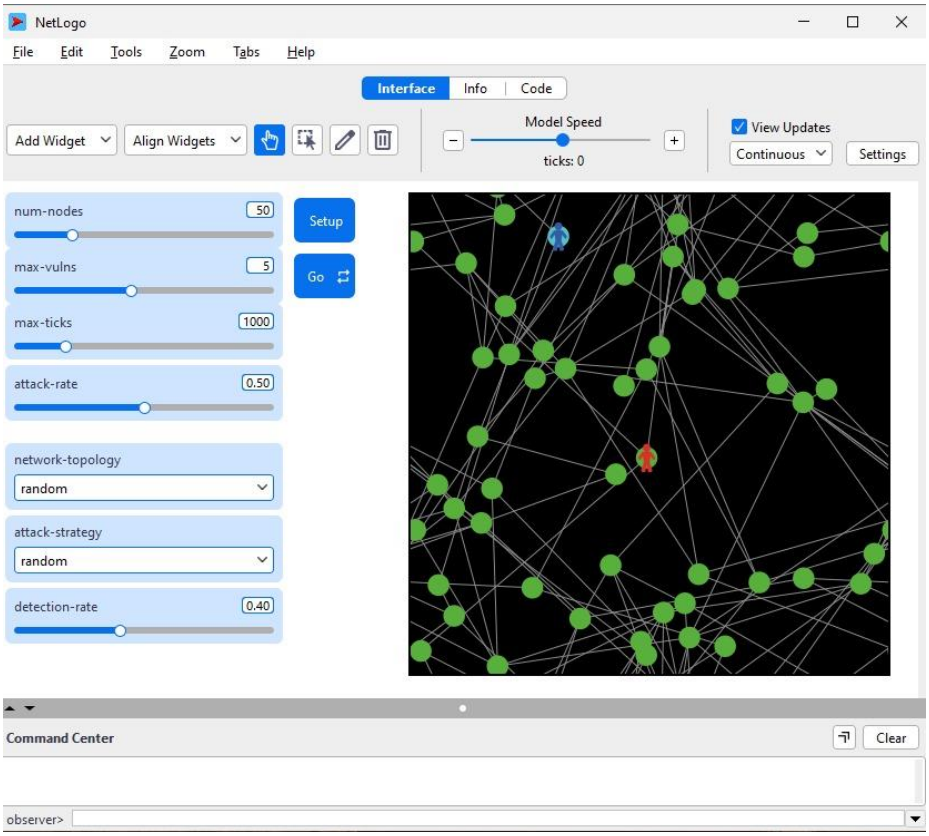
- attack-strategy [random / targeted]: strategia Red Agent (aleatoriu / preferă noduri cu vulnerabilități mari).
- max-ticks [100 – 1000, default: 300]: numărul maxim de pași de simulare.

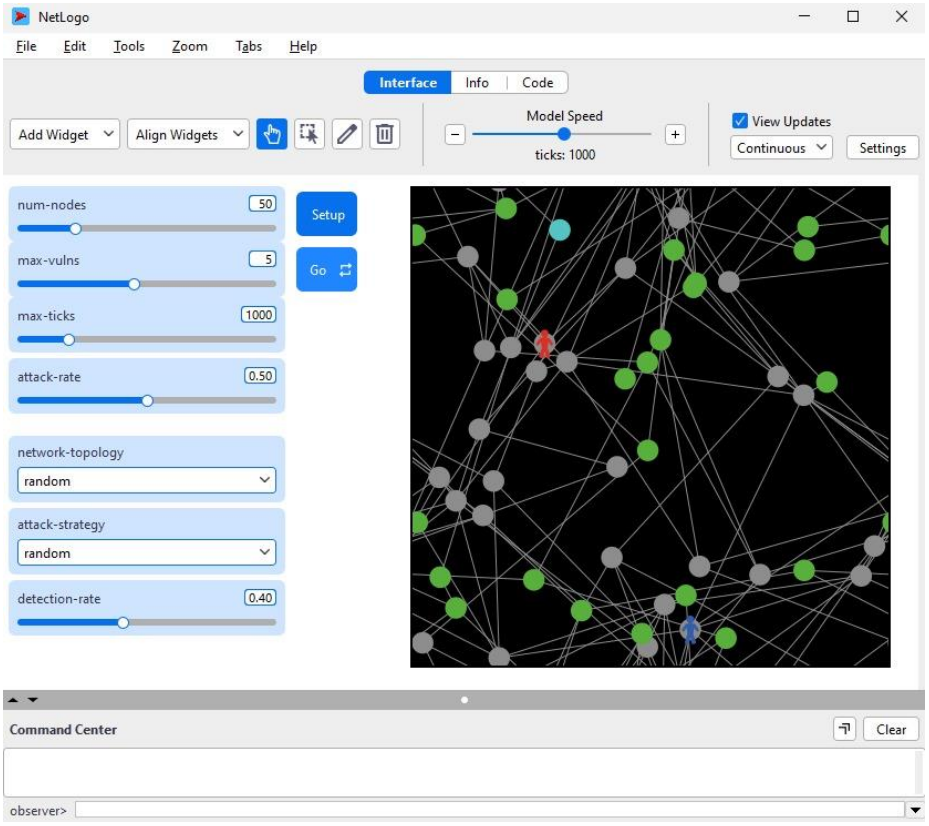
Elemente de inspirație: Conceptul de parametrizare a ratei de atac și detectare este inspirat direct din parametrii epsilon/epsilon-decay din Articolul 1 (controlul explorare vs. exploatare) și din parametrii de acuratețe DQN din Articolul 2.

21. Procesele detaliate și codul sursă NetLogo

Structura codului sursă NetLogo urmează procedurile de mai jos:

- to setup: inițializare completă a modelului (noduri, agenți, parametri).
- to go: bucla principală – apelează red-agent-move, blue-agent-patrol, update-indicators, check-stop.
- to red-agent-move: Red Agent selectează vecinul cu cele mai multe vulnerabilități (targeted) sau aleatoriu (random) și încearcă atacul.
- to blue-agent-patrol: Blue Agent scanează toți vecine la distanță ≤ 2 hops și izolează nodurile compromise detectate.
- to update-indicators: actualizarea plot-urilor și a monitoarelor de pe interfață.
- to-report count-compromised / count-isolated: funcții de raportare pentru indicatori.


NetLogo
File Edit Tools Zoom Tabs Help
Interface Info Code
Add Widget
Align Widgets
Model Speed
ticks: 0
View Updates
Continuous
Settings
num-nodes 50
max-vulns 5
max-ticks 1000
attack-rate 0.50
Setup
Go
network-topology
random
attack-strategy
random
detection-rate 0.40
Command Center
Clear
observer>


NetLogo
File Edit Tools Zoom Tabs Help
Interface Info Code
Add Widget
Align Widgets
Model Speed
ticks: 1000
View Updates
Continuous
Settings
num-nodes 50
max-vulns 5
max-ticks 1000
attack-rate 0.50
Setup
Go
network-topology
random
attack-strategy
random
detection-rate 0.40
Command Center
Clear
observer>

COD SURSĂ NetLogo:

```
globals [
  total-compromised
  total-isolated
  ticks-to-first-detection
  detection-happened?
]

breed [nodes a-node]
breed [red-agents red-agent]
breed [blue-agents blue-agent]

nodes-own [
  status         ;; "susceptible" | "compromised" | "isolated"
  vulnerabilities ;; integer 0..max-vulns
  is-gateway     ;; boolean
]

red-agents-own [
  nodes-compromised
  energy
]

blue-agents-own [
  nodes-isolated
```

```
  response-time
]

to setup
  clear-all
  set detection-happened? false
  set ticks-to-first-detection -1

  create-nodes num-nodes [
    set shape "circle"
    set color green
    set status "susceptible"
    set vulnerabilities random (max-vulns + 1)
    set is-gateway false
    setxy random-xcor random-ycor
    set size 1.5
  ]

  ifelse network-topology = "random" [
    ask nodes [
      ask other nodes [
        if random-float 1 < 0.05 [
          create-link-with myself
        ]
      ]
```

```
  ]
] [
  let sorted-nodes sort-on [count link-neighbors] nodes
  foreach sorted-nodes [ n ->
    if [count link-neighbors] of n < 3 [
      ask n [
        let target one-of other nodes with [self != n]
        if target != nobody [ create-link-with target ]
      ]
    ]
  ]
]

ask one-of nodes [
  set is-gateway true
  set color cyan
]

create-red-agents 1 [
  set shape "person"
  set color red
  set size 2
  set nodes-compromised 0
  set energy 100
  let start-node one-of nodes with [not is-gateway]
```

```
    if start-node != nobody [ move-to start-node ]
  ]

  create-blue-agents 1 [
    set shape "person"
    set color blue
    set size 2
    set nodes-isolated 0
    set response-time 0
    let start-node one-of nodes with [is-gateway]
    if start-node != nobody [ move-to start-node ]
  ]

  reset-ticks
end

to go
  if ticks >= max-ticks [ stop ]
  if not any? nodes with [status = "susceptible"] [ stop ]

  red-agent-move
  blue-agent-patrol
  update-indicators

  tick
```

```
end

to red-agent-move
  ask red-agents [
    let current-node one-of nodes-here
    if current-node != nobody [
      let target nobody
      let my-neighbors [link-neighbors] of current-node

      ifelse attack-strategy = "targeted" [
        let eligible-neighbors my-neighbors with [status = "susceptible"]
        if any? eligible-neighbors [
          let max-v max [vulnerabilities] of eligible-neighbors
          set target one-of eligible-neighbors with [vulnerabilities = max-v]
        ]
      ] [
        set target one-of my-neighbors with [status = "susceptible"]
      ]

      if target != nobody [
        if random-float 1 < attack-rate [
          ask target [
            set status "compromised"
            set color red
          ]
```

```
          set nodes-compromised nodes-compromised + 1
          move-to target
        ]
      ]
    ]
  ]
end

to blue-agent-patrol
  ask blue-agents [
    let current-node one-of nodes-here
    if current-node != nobody [
      let next-step one-of [link-neighbors] of current-node
      if next-step != nobody [ move-to next-step ]
    ]

    let scan-radius 5
    let nearby nodes in-radius scan-radius

    ask nearby [
      if status = "compromised" [
        if random-float 1 < detection-rate [
          set status "isolated"
          set color grey
```

```
          if not detection-happened? [
            set detection-happened? true
            set ticks-to-first-detection ticks
          ]

          ask myself [ set nodes-isolated nodes-isolated + 1 ]
        ]
      ]
    ]
  ]
end

to update-indicators
  set total-compromised count nodes with [status = "compromised"]
  set total-isolated     count nodes with [status = "isolated"]
end

to-report pct-compromised
  ifelse num-nodes > 0 [
    report (count nodes with [status = "compromised"] / num-nodes) * 100
  ] [ report 0 ]
end

to-report pct-isolated
  ifelse num-nodes > 0 [
```

```
    report (count nodes with [status = "isolated"] / num-nodes) * 100

  ] [ report 0 ]

end
```

Elemente de inspirație: Procedurile red-agent-move și blue-agent-patrol sunt direct inspirate din structura de atac/apărare descrisă în Articolul 1 (agentul DRL care selectează acțiuni bazate pe starea rețelei). Logica de izolare automată a nodurilor compromise este preluată conceptual din Articolul 2 (răspunsul automatizat al Defence Agent).

22. Opinie critică despre modelul conceput vs. articolele studiate

Modelul conceput capturează esența dinamicii atac-apărare descrisă în articolele studiate, dar la un nivel de abstractizare mult mai ridicat. Față de Articolul 1, modelul NetLogo nu implementează un algoritm de reinforcement learning propriu-zis – Red Agent acționează cu o probabilitate fixă (attack-rate), nu cu o politică DQN antrenată. Aceasta simplifică considerabil implementarea, dar sacrifică adaptabilitatea dinamică a agentului la stările anterioare. Față de Articolul 2, modelul nostru nu integrează date reale de trafic de rețea și nu are un mecanism de detecție de anomalii bazat pe ML – detecția Blue Agent este pur probabilistică. Prin urmare, rezultatele obținute sunt utile pentru înțelegerea conceptuală a propagării atacurilor și a impactului ratei de detectare, dar nu pot fi direct aplicate în scenarii reale fără adăugarea unor straturi de complexitate. O îmbunătățire viitoare ar putea consta în înlocuirea probabilității fixe de atac cu o funcție Q-learning simplificată, apropiind modelul de abordarea din Articolul 1, și în calibrarea parametrilor pe baza distribuțiilor statistice din CICIDS2017, conform Articolului 2.